

Élément du Module : *Machine Learning*

Enseignant/e (s) : Mme. Azroumali, Mme. Bajja, Mme. Bousmar, Mme. Charifi, Mme. Chrit,
Mme. Halhoul Merabet, Mme. Ouzif, Mme. Sadouk.

Partie 01 (Questions de Cours)

1. On vous fournit un jeu de données contenant :

- Des valeurs manquantes,
- Des variables catégorielles,
- Des variables numériques avec des ordres de grandeur très différents.

Expliquez quelles étapes de prétraitement vous appliquez, dans quel ordre, et pourquoi.

2. Expliquez pourquoi une normalisation min-max ou z-score est indispensable avant d'appliquer :

- KNN
- K-Means

Que se passe-t-il concrètement si cette étape est ignorée ?

3. Expliquez le rôle de l'une des métriques suivantes dans l'évaluation d'un **modèle de régression** :
MAE ou MSE ou R^2

4. Une entreprise de télécommunication souhaite mieux comprendre le comportement de ses clients afin d'adapter ses offres commerciales à leur penchant.

Elle dispose d'une base de données contenant, pour chaque client, les variables suivantes :

- / Consommation mensuelle des données (Go)
- / Nombre moyen d'appels effectué par mois
- / Durée moyenne des appels
- / Montant mensuel de la facture

L'entreprise ne dispose d'aucune information au préalable sur les catégories de clients existantes, mais souhaite entamer une étude **pour identifier et regrouper automatiquement les clients ayant des comportements similaires, en utilisant l'algorithme K-Means.**

- a) Qu'elle est l'utilité et le rôle de l'utilisation d'un algorithme d'apprentissage non supervisé pour répondre à cette problématique métier.
- b) Décrivez, étape par étape, le principe de fonctionnement du K-Means.
- c) On considère le cas où le nombre de clusters K choisi est très grand ($K \rightarrow$ nombre de clients). Expliquez comment ce choix affecte les performances du modèle, en analysant la qualité empirique du clustering (inertie et variance intra cluster), et l'interprétabilité des résultats.

-
- L'usage des téléphones portables et de tout objet connecté (montre intelligente, etc.) **est strictement interdit.**
 - Aucun document **n'est autorisé.**
 - Calculatrice **non autorisée.**

Exercice 01 : Régression linéaire

On étudie le **salaire mensuel** d'un employé en fonction de x_1 (le nombre d'années d'expérience) et x_2 (le nombre de certifications professionnelles).

Employé	Expérience (ans) (x_1)	Certifications (x_2)	Salaire (kDh) (y)
A	1	0	6
B	3	1	9
C	5	2	13
D	7	3	17

- Donner l'expression du modèle de régression linéaire multiple pour ce jeu de données.
- Construire la matrice X et le vecteur Y .

Exercice 02 : Prétraitement des Données

Une entreprise de **crédit à la consommation** souhaite préparer ses données clients avant d'appliquer des algorithmes de classification (KNN) et de clustering (K-Means).

Le tableau ci-dessous représente un extrait des données brutes.

ID	Âge	Revenu (Dhs)	Ville	Ancienneté (années)	Nombre de crédits	Satisfaction
1	25	4500	Rabat	2	1	Moyenne
2	34	8200	Casablanca	5	3	Bonne
3	NaN	6000	Rabat	3	2	Très bonne
4	46	15000	Marrakech	10	5	Très bonne
5	29	NaN	Casablanca	1	1	Mauvaise
6	38	9000	Fès	NaN	4	Bonne

- Indiquez le type de donnée (nominale, ordinale, intervalle ou ratio) pour les variables suivantes :
 - Ville
 - Satisfaction
 - Revenu
- Utilisez l'imputation par moyenne pour corriger la valeur manquante détectée sur la variable « âge ».
- Utilisez l'imputation par médiane pour corriger la valeur manquante sur la variable « Revenu (Dhs) ».
- Utilisez l'imputation par médiane pour corriger la valeur manquante sur la variable « Ancienneté (années) ».
- On considère les variables Âge, et Revenu qu'on souhaite normaliser.
 - Donnez la formule de normalisation z-score et expliquer son utilité.
 - Appliquez cette méthode de normalisation sur les deux variables et donner le résultat sous forme de deux colonnes.

Exercice 03 : Classification par KNN

Une banque souhaite **classer le profil de risque de ses clients** afin de décider si un crédit peut être accordé.

Chaque client est décrit par :

- Âge (en années)

- L'usage des téléphones portables et de tout objet connecté (montre intelligente, etc.) **est strictement interdit.**
- Aucun document **n'est autorisé.**
- Calculatrice **non autorisée.**

- Revenu mensuel (en milliers de dirhams)

La variable cible est :

- Risque crédit :
 - 1 → Faible (classe positive)
 - 0 → Élevé (classe négative)

Données d'apprentissage :

Client	Âge	Revenu (kDhs)	Risque
A	23	4.5	1
B	28	6.0	0
C	35	7.5	0
D	42	9.0	0
E	30	4.0	1
X	32	6.5	

On souhaite prédire le risque crédit du client suivant : Client X (voir le tableau)

- Après la normalisation min-max des variables Âge et Revenu :
 - Écrivez la formule de la distance euclidienne.
 - Appliquer le KNN pour K=3 et déterminez la classe prédite.
 - Appliquer le KNN pour K=5 et déterminez la classe prédite.

Vos réponses doivent être justifier et inclure les étapes suivies pour appliquer le KNN .

- Expliquez pourquoi la classe prédite peut changer lorsque la valeur de K change.
- Sur un jeu de test, on obtient la matrice de confusion suivante :

	Prédit 1 (Positive)	Prédit 0 (Négative)
Réel 1 (Positive)	6	2
Réel 0 (Négative)	1	3

- Calculez :
 - L'Accuracy
 - Le Recall
- Interprétez les résultats obtenus :
 - Que signifie concrètement la valeur de l'Accuracy pour ce modèle ?
 - Que signifie la valeur du Recall de la classe *Risque élevé* dans le contexte d'octroi de crédit ?
 - Ce modèle est-il **fiable** pour détecter les clients à risque ? Justifiez.

- L'usage des téléphones portables et de tout objet connecté (montre intelligente, etc.) **est strictement interdit.**
- Aucun document **n'est autorisé.**
- Calculatrice **non autorisée.**